📚 [LAB11] 지도학습 > 지도학습 > 시계열 분석 > Phophet (BaseModel)

📘 #01. 라이브러리 개요

Facebook(현 Meta)에서 개발한 **시계열 예측 라이브러리**

> https://facebook.github.io/prophet/

> https://peerj.com/preprints/3190.pdf

📝 [1] Prophet의 목적

- 시간에 따른 데이터의 **추세(Trend)** 파악
- 반복되는 **계절성(Seasonality)** 분석
- 공휴일·이벤트 효과 반영
- 미래 값 예측

📝 [2] Prophet의 특징

- 결측치에 비교적 강함
- 불규칙한 간격 데이터 처리 가능
- 자동으로 추세 변화점(changepoint) 탐지
- 연/월/주 단위 계절성 자동 처리
- 파라미터 튜닝이 비교적 단순함

📝 [3] Prophet이 적합한 경우

- 매출 예측
- 방문자 수 예측
- 거래량 예측
- 트렌드 + 계절성이 존재하는 데이터

📘 #02. 준비작업

📝 [1] 패키지 참조

```
from hossam import *

from matplotlib import pyplot as plt
import seaborn as sb
import numpy as np
from pandas import to_datetime, DataFrame
from prophet import Prophet
from prophet.plot import add_changepoints_to_plot
from sklearn.metrics import mean_absolute_error, mean_squared_error
```

📝 [2] 데이터 가져오기

```
origin = load_data("air_passengers")
origin.head()
```

> 어느 항공사의 월간 탑승객 수 (출처: https://www.kaggle.com/datasets/rakannimer/air-passengers)

	Month	Passengers
0	1949-01-01	112
1	1949-02-01	118
2	1949-03-01	132
3	1949-04-01	129
4	1949-05-01	121

📝 [3] 데이터 프레임의 필드 이름 변경

prophet 라이브러리의 요구사항에 따라 날짜 필드의 이름을 `ds` 로, 데이터의 필드 이름을 `y` 로 변경해야 한다.

날짜의 데이터 타입은 `datetime` 형식이어야 한다.

> 날짜 변수가 인덱스가 아님에 유의

```
df_prophet = origin.rename(columns={'Month': 'ds', 'Passengers': 'y'})
df_prophet['ds'] = to_datetime(df_prophet['ds'])
df_prophet.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 144 entries, 0 to 143
Data columns (total 2 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   ds      144 non-null    datetime64[ns]
 1   y       144 non-null    int64
dtypes: datetime64[ns](1), int64(1)
memory usage: 2.4 KB
```

📘 #03. 시계열 데이터 준비

📝 [1] 데이터 분할

✏️ (1) 단순 비율 분할 (예: 80%/20%)

```python
# 분할 비율
split_ratio = 0.8

# 분할 인덱스
split_idx = int(len(df_prophet) * split_ratio)

# 훈련 / 검증 데이터
train = df_prophet.iloc[:split_idx]
test = df_prophet.iloc[split_idx:]

print("Train 기간:", train['ds'].min(), "~", train['ds'].max())
print("Valid 기간:", test['ds'].min(), "~", test['ds'].max())
```

```
Train 기간: 1949-01-01 00:00:00 ~ 1958-07-01 00:00:00
Valid 기간: 1958-08-01 00:00:00 ~ 1960-12-01 00:00:00
```

✏️ (2) 날짜 기준 분할 (예: 특정 시점 이후를 검증)

```python
# 검증 시작일 설정
split_date = "1958-08-01"

train = df_prophet[df_prophet['ds'] < split_date]
test = df_prophet[df_prophet['ds'] >= split_date]

print("Train 기간:", train['ds'].min(), "~", train['ds'].max())
print("Valid 기간:", test['ds'].min(), "~", test['ds'].max())
```

```
Train 기간: 1949-01-01 00:00:00 ~ 1958-07-01 00:00:00
Valid 기간: 1958-08-01 00:00:00 ~ 1960-12-01 00:00:00
```

📝 [2] 공휴일 데이터 설정

공휴일 효과를 기대할 수 없다면 이 과정은 생략할 수 있다.

✏️ Air Passengers Dataset의 특성

항목	내용
기간	1949-01 ~ 1960-12
빈도	월간(Monthly)
단위	항공기 탑승객 수
지역	미국 항공 수요로 간주

✏️ 1950년대 미국 항공 수요에 영향을 주는 대표 시즌

시즌	월	근거
Independence Day	7월	여름 휴가 성수기
Thanksgiving	11월	대규모 이동
Christmas	12월	연말 이동
Summer Vacation	6~8월	계절적 항공 수요 증가

✏️ 공휴일 데이터 생성하기

컬럼명이 고정되어 있다.

```python
# 전체 연도 범위
years = range(1949, 1961)

holiday_list = []

for y in years:
    holiday_list.extend([
        # Independence Day → 7월 효과
        {'holiday': 'independence_day', 'ds': f'{y}-07-01'},

        # Thanksgiving → 11월 효과
        {'holiday': 'thanksgiving', 'ds': f'{y}-11-01'},

        # Christmas → 12월 효과
        {'holiday': 'christmas', 'ds': f'{y}-12-01'},
```

```
        # Summer Vacation 시작 → 6월
        {'holiday': 'summer_vacation', 'ds': f'{y}-06-01'}
    ])

holidays = DataFrame(holiday_list)
holidays['ds'] = to_datetime(holidays['ds'])

# 공휴일 효과 없음으로 설정 (다음 단계에서 설명)
holidays['lower_window'] = 0
holidays['upper_window'] = 0

holidays.head()
```

	holiday	ds	lower_window	upper_window
0	independence_day	1949-07-01	0	0
1	thanksgiving	1949-11-01	0	0
2	christmas	1949-12-01	0	0
3	summer_vacation	1949-06-01	0	0
4	independence_day	1950-07-01	0	0

✏️ 공휴일 효과

Prophet의 공휴일 효과는 하루짜리 충격(impulse) 이 아니라 지정한 범위까지 영향이 확장되는 구조임.

파라미터	의미
`lower_window`	공휴일 **이전** 며칠까지 효과를 줄 것인지
`upper_window`	공휴일 **이후** 며칠까지 효과를 줄 것인지

예시

크리스마스 전후 4일간 holiday 효과가 들어감.

날짜	효과 적용 여부
12-23	✔ (−2일)
12-24	✔ (−1일)
12-25	✔ (당일)
12-26	✔ (+1일)
12-27	✖

✏️ 공휴일 효과 포함 샘플 코드

```
hd_test = DataFrame({
    'holiday': 'christmas',
```

```
    'ds': to_datetime(['2020-12-25']),
    'lower_window': -2,
    'upper_window': 1
})

hd_test
```

	holiday	ds	lower_window	upper_window
0	christmas	2020-12-25	-2	1

✏️ 실습 데이터에 대한 공휴일 효과

Air Passengers처럼 월 단위 데이터에서는:

상황	권장 설정
특정 하루 의미 없음	`lower_window = 0`
월 전체 영향 가정	월 첫날로 통일

- 월간 데이터에서 ±1일은 의미 없음
- 월 단위 모델에서는 1개월이 최소 단위

✏️ 언제 window를 크게 설정하나?

상황	예시
소비가 미리 증가	블랙프라이데이
명절 전 이동 증가	설날
명절 후 휴무	추석 연휴

📘 #03. 시계열 학습 모델 구현

📝 [1] 기본 모형 설정

파라미터	설정 가능 값	권장값 (일반 시계열)	의미 (쉽게 설명)
growth	`'linear'`, `'logistic'`	`'linear'`	데이터가 시간이 지나면서 어떻게 늘어나는지 정하는 옵션. `linear` 는 계속 일정하게 증가하거나 감소하는 형태. `logistic` 는 어느 시점 이후 더 이상 크게 늘지 못하고 한계에 가까워지는 형태. 대부분 일반 수요 예측은 linear 사용.
changepoint_prior_scale	0.001 ~ 0.5 (실무 범위)	0.05	추세가 중간에 꺾이는 정도를 얼마나 허용할지 결정. 값이 크면 모델이 추세 변화를 민감하게

			따라감(복잡해짐). 값이 작으면 부드럽게 유지됨. 보통 0.05가 안정적 시작점.
seasonality_mode	`'additive'` , `'multiplicative'`	`'additive'`	계절 효과가 일정한 크기로 반복되는지, 아니면 전체 수준이 커질수록 같이 커지는지 결정. 매출처럼 규모가 커질수록 변동폭도 커지면 multiplicative 사용. 일반적 실습은 additive로 시작.
yearly_seasonality	`True` , `False` , 정수(차수 지정)	`True`	1년 주기의 반복 패턴을 자동으로 학습할지 여부. 월간 데이터나 장기 데이터에서는 거의 항상 필요.
weekly_seasonality	`True` , `False` , 정수	일별 데이터: True`` 월별 데이터: `False`	요일별 반복 패턴을 반영할지 여부. 월간 데이터에서는 의미 없음. 일 단위 데이터에서 사용.
daily_seasonality	`True` , `False` , 정수	대부분 `False`	하루 안에서 시간대별 반복이 있는 경우 사용 (예: 시간 단위 데이터). 일/월 데이터에서는 필요 없음.
holidays	공휴일 DataFrame	도메인 기반 설정	특정 날짜(또는 기간)에 수요가 특별히 증가·감소하는 효과를 추가. 예: 명절, 크리스마스, 여름 휴가. 데이터 주기에 맞게 날짜 단위를 맞춰야 함.
seasonality_prior_scale	0.01 ~ 20	10 (기본값)	계절 효과를 얼마나 강하게 반영할지 결정. 값이 크면 계절성을 적극 반영. 너무 크면 과적합 가능.
holidays_prior_scale	0.01 ~ 20	10 (기본값)	공휴일 효과의 크기를 얼마나 인정할지 조절. 특정 이벤트 영향이 강하다고 확신할 때 조정 가능.

✏️ 데이터 유형별 권장 조합

데이터 주기	추천 설정
월간 데이터	yearly=True, weekly=False, daily=False
일별 데이터	yearly=True, weekly=True, daily=False
시간 단위 데이터	yearly=True, weekly=True, daily=True

```
model = Prophet(
    growth='linear',
    changepoint_prior_scale=0.05,
    seasonality_mode='additive',
    yearly_seasonality=True,
    weekly_seasonality=False,    # 월간 데이터이므로 False
    daily_seasonality=False,
    holidays=holidays,
    seasonality_prior_scale=10,
    holidays_prior_scale=10
)

model.fit(train)
```

```
07:49:35 - cmdstanpy - INFO - Chain [1] start processing
07:49:35 - cmdstanpy - INFO - Chain [1] done processing




<prophet.forecaster.Prophet at 0x31b34f710>
```

📝 [2] 학습결과를 활용하여 예측

`periods` 는 예측할 기간 (일(`D`), 월(`M`) 단위 설정 가능 / 기본은 일단위)

```
future = model.make_future_dataframe(periods=len(test), freq='M')
forecast = model.predict(future)
forecast.head()
```

	ds	trend	yhat_lower	yhat_upper	trend_lower	trend_upper	additive_terms	additive_terms_lower
0	1949-01-01	109.538	69.289	111.322	109.538	109.538	-19.517	-19.517
1	1949-02-01	111.674	60.956	104.344	111.674	111.674	-27.870	-27.870
2	1949-03-01	113.604	96.431	141.147	113.604	113.604	4.277	4.277
3	1949-04-01	115.741	87.723	132.661	115.741	115.741	-5.547	-5.547
4	1949-05-01	117.808	90.581	134.142	117.808	117.808	-6.674	-6.674

📝 [3] 예측 결과에 대한 시각화

시각 요소	색상/형태	의미	해석 포인트
Observed data points	검은 점	실제 학습 데이터(train)의 관측값	모델이 학습한 실제 데이터. 예측선이 이 점들을 얼마나 잘 따라가는지 확인하는 기준.
Forecast (yhat)	파란색 실선	모델이 추정한 예측값	모델이 판단한 "가장 가능성 높은 값". 미래 구간에서도 동일한 방식으로 계산됨.
Uncertainty interval	반투명 파란 영역	예측의 신뢰 구간	값이 존재할 가능성이 높은 범위. 넓을수록 불확실성이 큼. 미래로 갈수록 보통 점점 넓어짐.
Test(real)	주황색 점선	검증 데이터(valid/test)의 실제값	모델이 보지 못한 데이터. 파란 실선과 얼마나 가까운지로 일반화 성능 판단.

- **모델 적합 확인 (Train 구간)**
  - 검은 점과 파란 선이 잘 겹치면 적합 양호
  - 큰 편차가 지속되면 언더피팅 가능
- **일반화 확인 (Test 구간)**
  - 검은 점선(test)이 파란 선과 가깝다면 예측 성능 양호
  - 지속적으로 위/아래로 벗어나면 편향 발생

- **불확실성 해석**
  - 신뢰 구간이 급격히 넓어지면:
    - 장기 예측
    - 변동성 증가
    - 데이터 부족 가능성

```
fig = model.plot(forecast, figsize=(20, 7), xlabel='Date', ylabel='Passengers',
        uncertainty=True)
ax = fig.gca()
ax.set_title("시계열 예측")

# 실제 검증 데이터는 직접 추가한다.
sb.lineplot(data=test, x='ds', y='y', ax=ax, color='#ff6600', linestyle="--",
        label='test(real)')

plt.show()
plt.close()
```

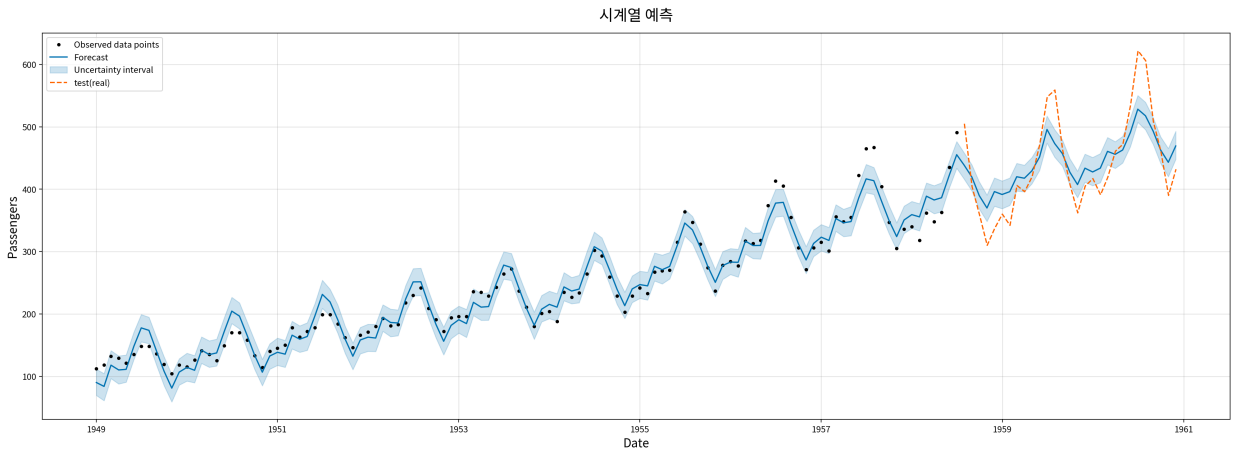

📝 [4] changepoint 를 추가한 시각화

`changepoint` - Trend가 변화하는 지점

- fig.gca() : 시계열 그래프
- model : 미리 만들어준 Prophet 객체
- forecast : predict 결과

```
fig = model.plot(forecast, figsize=(20, 7), xlabel='Date', ylabel='Passengers',
        uncertainty=True)
ax = fig.gca()
add_changepoints_to_plot(ax, model, forecast)

ax.set_title("시계열 예측")
sb.lineplot(data=test, x='ds', y='y', ax=ax, color='#ff6600', linestyle="--",
        label='test(real)')
```

```
plt.show()
plt.close()
```

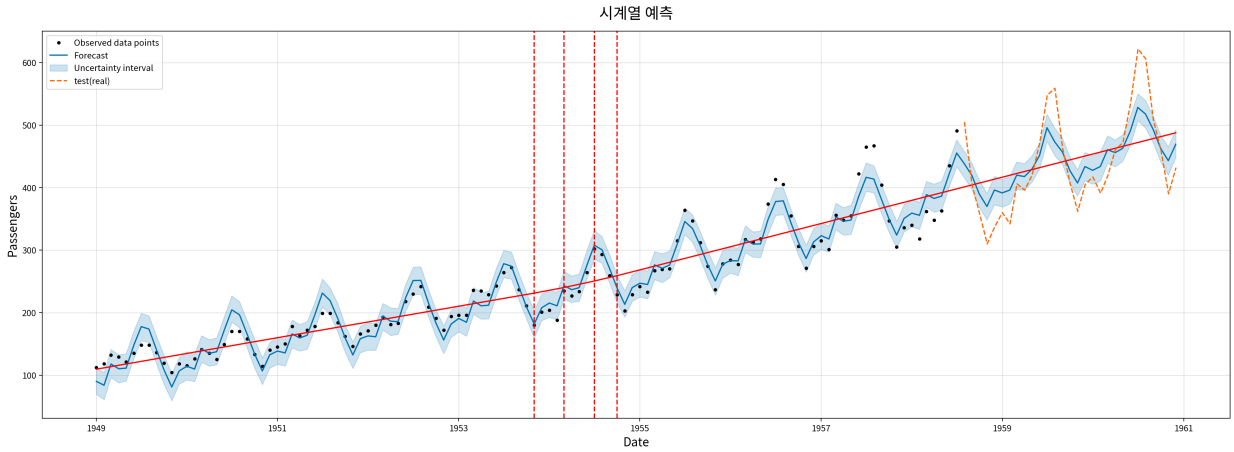

📝 [4] 모델이 갖는 컴포넌트 확인 (성분분해)

```
fig = model.plot_components(forecast, figsize=(20, 15))
ax = fig.gca()
plt.show()
plt.close()
```

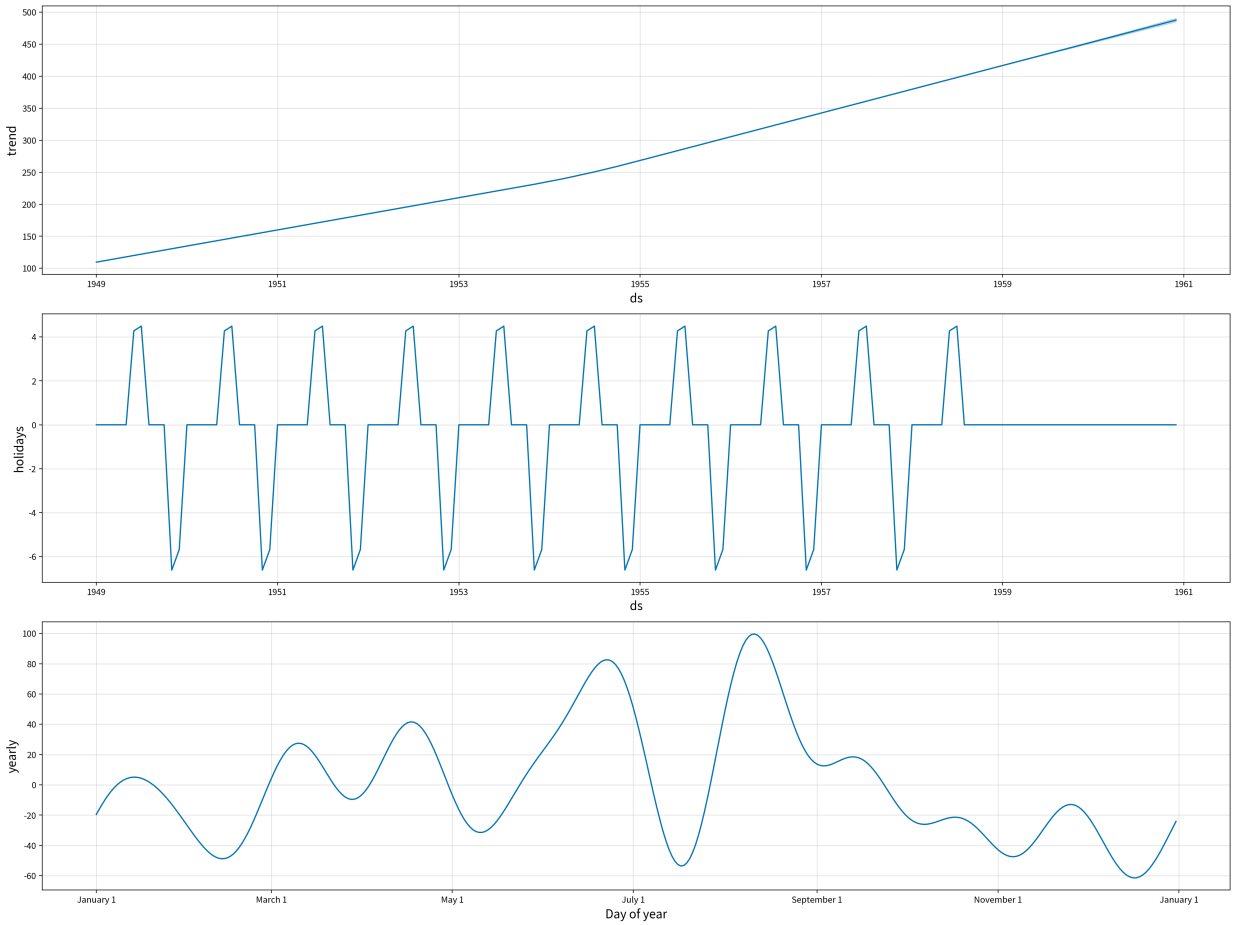

📘 #04. 성능평가

📝 실제 y값과 예측 y값 얻기

```
y = test['y'].values
y
```

```
array([505, 404, 359, 310, 337, 360, 342, 406, 396, 420, 472, 548, 559,
       463, 407, 362, 405, 417, 391, 419, 461, 472, 535, 622, 606, 508,
       461, 390, 432])
```

```
yhat = forecast['yhat'].values[-len(test):]
yhat
```

```
array([438.63917692, 419.61318436, 389.72625815, 369.8669195 ,
       396.17536784, 391.53191933, 396.06555393, 419.98751951,
       417.61482918, 429.40084989, 451.64055858, 495.86742321,
       473.24833904, 457.13173799, 427.3823127 , 407.42212537,
       433.73342902, 427.64798779, 433.8255703 , 460.65333199,
       455.92675973, 462.88563281, 490.8103065 , 528.34481687,
       517.73683825, 493.05367733, 462.83660633, 443.15783319,
       469.35060735])
```

📝 Test(Validation) 성능 계산

```
valid_mae = mean_absolute_error(y, yhat)
valid_mse = mean_squared_error(y, yhat)
valid_rmse = np.sqrt(valid_mse)
```

📝 Train 성능 계산

```
# train 구간 예측값 추출
yhat_train = forecast['yhat'].values[:-len(test)]
y_train = train['y'].values

train_mae = mean_absolute_error(y_train, yhat_train)
train_mse = mean_squared_error(y_train, yhat_train)
train_rmse = np.sqrt(train_mse)
```

📝 과적합 판단

조건	해석
Valid RMSE ≈ Train RMSE	일반화 양호
Valid RMSE > Train RMSE (차이 큼)	과적합 의심
둘 다 큼	언더피팅 가능

```
rmse_gap = valid_rmse - train_rmse
gap_ratio = rmse_gap / train_rmse

if gap_ratio > 0.2:
    overfit_flag = "과적합 의심"
elif gap_ratio > 0.1:
    overfit_flag = "약한 과적합 가능성"
else:
    overfit_flag = "일반화 양호"
```

📝 최종 성능표 생성

```
result = DataFrame({
    "Train_MAE": [train_mae],
    "Train_RMSE": [train_rmse],
    "Valid_MAE": [valid_mae],
    "Valid_RMSE": [valid_rmse],
    "RMSE_차이": [rmse_gap],
    "차이비율": [gap_ratio],
    "과적합의심여부": [overfit_flag]
})

result
```

	Train_MAE	Train_RMSE	Valid_MAE	Valid_RMSE	RMSE_차이	차이비율	과적합의심여부
0	13.177	16.933	36.680	44.692	27.759	1.639	과적합 의심

✏️ 시계열 분석에서의 과적합과 일반 ML에서의 과적합 차이

구분	일반 ML	시계열
데이터 구조	독립 샘플	시간 의존성 존재
검증 방식	랜덤 분할	시간 순서 유지
과적합 의미	훈련만 잘 맞음	과거만 잘 맞고 미래 실패

.

- **“과거 패턴을 지나치게 세밀하게 따라간 결과 미래 예측이 불안정해지는 현상”**
  - 시계열은 기본적으로 미래로 갈수록 불확실성이 증가하고 구조 변화(regime change)가 가능하기 때문에 완벽한 일반화 개념이 약함
  - 따라서 과적합 여부는 “절대적 판단”이 아니라 “예측 안정성 점검” 개념에 가까움.

✏️ 실무적 해석 포인트

항목	중요성
예측 방향성	상승/하락 추세 맞는가
신뢰구간 안정성	불확실성 과도하게 넓은가
구조 일관성	모델이 설명 가능한가